

人工智能发展现状分析：技术进展、市场应用与治理趋势

目录

- 一、背景
 - 1、本章摘要
 - 2、正文
- 二、现状
 - 1、本章摘要
 - 2、正文
- 三、趋势
 - 1、本章摘要
 - 2、正文
- 四、建议
 - 1、本章摘要
 - 2、正文

一、背景

1、本章摘要

人工智能自1956年达特茅斯会议提出概念以来，经历了六十余年起伏发展，2011年前后进入以深度神经网络为代表的蓬勃发展期。当前人工智能总体上仍处于专用智能取得突破、通用智能尚在起步的阶段，其发展已被主要国家提升至国家竞争力和国家安全的战略层面。中国自2015年起密集出台人工智能政策，形成从国家规划到地方实施方案的政策体系；全球层面，投资、论文、专利和监管活动持续增长，但区域差异显著。本章交代人工智能发展的宏观背景，界定研究对象为人工智能技术与产业发展现状，并说明分析所依据的时间、地域和统计口径。

2、正文

人工智能正成为继蒸汽机、发电机、计算机和互联网之后，推动人类进入智能时代的又一决定性技术力量。全球产业界普遍认识到人工智能技术引领新一轮产业变革的意义，世界主要发达国家均将发展人工智能作为提升国家竞争力和维护国家安全的重大战略，力图在国际科技竞争中掌握主导权[1]。这一判断构成了本报告考察人工智能现状的基本前提：人工智能已从实验室研究议题演变为涉及技术、产业、治理和社会的综合性议题。

从概念和历史维度看，人工智能是研究开发能够模拟、延伸和扩展人类智能的理论、方法、技术及应用系统的一门技术科学，其研究目标涵盖机器“会听、会看、会说、会思考、会学习、会行动”等多个能力方向。1956年夏，麦卡锡、明斯基等科学家在美国达特茅斯学院研讨“如何用机器模拟人的智能”，首次提出“人工智能”概念，标志着该学科的诞生[1]。此后六十余年，人工智能发展并非线性推进，而是经历了起步发展期（1956年—20世纪60年代初）、反思发展期（20世纪60年代—70年代初）、应用发展期（20世纪70年代初—80年代中）、低迷发展期（20世纪80年代中—90年代中）、稳步发展期（20世纪90年代中—2010年）和蓬勃发展期（2011年至今）六个阶段[1]。这一分期表明，人工智能的进展伴随着期望高涨与预期落空的反复，理解其现状需要放在长周期历史脉络中考察。

当前阶段的界定具有明确的时点特征。2011年以来，随着大数据、云计算、互联网、物联网等信息技术的发展，泛在感知数据和图形处理器等计算平台推动以深度神经网络为代表的人工智能技术飞速发展，图像分类、语音识别、知识问答、人机对弈、无人驾驶等技术实现了从“不能用、不好用”到“可以用”的突破，迎来爆发式增长[1]。与此对应，斯坦福大学《2025年人工智能指数报告》将2024年描述为人工智能在多个领域取得显著进展的一年，并指出人工智能已从边缘领域成为业务价值的核心驱动力[2]。本报告对“现状”的考察，即以这一蓬勃发展期为基本时间背景。

在技术能力层面，需要区分专用智能与通用智能两个口径。面向特定任务的专用人工智能系统由于任务单一、需求明确、应用边界清晰，形成了单点突破，在局部智能水平的单项测试中可

以超越人类智能，例如阿尔法狗（AlphaGo）在围棋比赛中战胜人类冠军，人工智能程序在大规模图像识别和人脸识别中达到超越人类的水平[1]。但通用人工智能领域的研究与应用仍然任重道远，当前人工智能系统在信息感知、机器学习等“浅层智能”方面进步显著，在概念抽象和推理决策等“深层智能”方面能力仍较薄弱[1]。这一区分对分析口径具有重要意义：讨论“人工智能超越人类”时需要明确所指是特定任务还是通用能力，否则容易产生认知偏差。求是网2019年的评述即指出，社会上存在认为人工智能系统智能水平即将全面超越人类水平等“炒作”，这些错误认识会给人工智能发展带来不利影响，因此制定战略、方针和政策首先要准确把握技术和产业发展的现状[1]。

从最新技术进展看，人工智能在标准化比较基准上的表现持续提升。2023年研究人员推出 MMMU、GPQA 和 SWE-bench 等新型比较基准后，仅一年时间，相关得分分别提高 18.8、48.9 和 67.3 个百分点；在 SWE-bench 编程测试中，人工智能系统的解题能力从 2023 年解决 4.4% 的问题跃升至 2024 年的 71.7% [2]。同时，开源模型与闭源模型的性能差距基本消失，顶尖闭源模型的性能优势从 2024 年 1 月的 8.0% 缩小至 2025 年 2 月的 1.7% [2]。中美人工智能模型能力差距也大幅收窄，在 MMLU、MMMU、MATH 和 HumanEval 等基准中，差距分别从 2023 年底的 17.5、13.5、24.3 和 31.6 个百分点收窄至 2024 年末的 0.3、8.1、1.6 和 3.7 个百分点 [2]。这些数据表明，技术能力的竞争格局正在快速演变，但复杂推理仍是人工智能面对的难题，系统仍无法可靠解决本可通过逻辑推理获得确定性答案的问题 [2]。

在产业与投资层面，人工智能的商业化进程明显加速。2024 年，全球企业人工智能投资规模创历史新高，美国私人人工智能投资达 1091 亿美元，约为中国（93 亿美元）的 12 倍、英国（45 亿美元）的 24 倍；生成式人工智能吸引全球 339 亿美元私人投资，同比增长 18.7%；78% 的企业在 2024 年应用了人工智能技术，较前一年的 55% 有所提升 [2]。在应用效益方面，在客户服务运营中使用人工智能的企业中有 49% 的受访者报告实现降本，营销与销售部门应用人工智能的企业中有 71% 的受访者报告收入提升，但成本降幅大多不足 10%，收入增幅普遍低于 5% [2]。人工智能应用呈现明显的区域差异，大中华区是同比增长率最高的地区之一，企业人工智能采用率提升了 27%，欧洲紧随其后实现 23% 的增长 [2]。

在政策与治理层面，中国形成了较为密集的政策体系。2015 年 5 月，国务院签批《中国制造 2025》，首次以战略文件形式将人工智能制造列入国家重点建设“五大工程”之一 [3]。2017 年 7 月，国务院发布《新一代人工智能发展规划》，将新一代人工智能放在国家战略层面部署，描绘了面向 2030 年的发展路线图 [1]。据政策文本量化研究统计，2016 年至 2020 年间，从国家部委到地方政府陆续出台了包括《“互联网+”人工智能三年行动实施方案》《促进新一代人工智能产业发展三年行动计划（2018—2020 年）》以及浙江、辽宁、上海、江西、福建、山东、广东、四川、安徽、云南等省市的新一代人工智能发展规划或实施意见在内的数十项政策文件 [3]。该研究以《中国制造 2025》为时间节点，在中国社会科学引文数据库中检索得到 1358 篇样本文献，采用复合关系分析与关键词引用突变相结合的方法探究我国人工智能研究前沿趋势 [3]。这一政策密度反映出中国将人工智能作为战略性领域的明确取向。

全球治理层面，人工智能监管活动同步升温。2024 年，美国共发布 59 项人工智能相关监管条例，远高于 2023 年的 25 项，发布机构数达到 42 个，为历史最高 [2]。全球立法程序中“人工智能”

一词的提及次数从2016年起增长超过九倍，2023年为1557次，2024年增长至1889次，增幅达21.3%^[2]。2024年，多个国际组织相继发布规范性框架：经合组织更新了其人工智能原则，非洲联盟推出非洲大陆人工智能战略，欧盟通过了《人工智能法》，这是全球主要经济体首个全面的人工智能监管框架，该法案按风险对人工智能进行分类并相应监管^[2]。这些进展表明，人工智能治理正从孤立的国家行动向协同全球治理转变。

二、现状

1、本章摘要

当前人工智能处于深度学习驱动的蓬勃发展期，专用智能已实现重要突破，通用人工智能尚处于起步阶段。技术层面，大语言模型与推理范式快速演进，前沿模型性能趋于收敛，开源与闭源模型差距基本消失，中美模型能力差距显著收窄，但复杂推理、数据可得性和可信度仍是主要约束。市场层面，全球私人投资与企业应用在2024年明显反弹，应用呈现显著区域差异，大中华区采用率增速居前。治理层面，各国政府从讨论转向投资与监管，全球协作机制加速成型，但负责任的人工智能评估尚未普及，公众信任持续走低。需注意，本章证据以2019年与2025年两份公开资料为主，时间跨度较大，部分判断受口径与时效限制。

2、正文

****总体判断：专用智能取得突破，通用智能仍在起步。****从可应用性看，人工智能大体可分为专用人工智能和通用人工智能。面向特定任务的专用系统因任务单一、边界清晰，形成了单点突破，在局部单项测试中可以超越人类智能，近期进展主要集中在专用智能领域，例如围棋对弈、大规模图像识别和人脸识别等已达到或超越人类水平；而通用人工智能领域的研究与应用仍然任重道远，当前系统在信息感知、机器学习等“浅层智能”方面进步显著，但在概念抽象和推理决策等“深层智能”方面能力仍薄弱，总体发展水平仍处于起步阶段[1]。这一判断在技术演进脉络上得到印证：人工智能的技术演进大致可归纳为逻辑推理、专家系统、机器学习和深度学习四类技术，以及规则、专家系统、统计学习、算法通用和知识通用五个阶段；2020年大语言模型的到来使发展开始切换赛道，转向探索“通用人工智能”（AGI）方向[4]。

****技术能力：基准测试快速突破，复杂推理与可信度仍是瓶颈。****2023年研究人员推出MMMU、GPQA和SWE-bench等新型比较基准，仅一年后性能大幅提升：MMMU和GPQA得分分别提高18.8和48.9个百分点，SWE-bench编程测试的解题率从2023年的4.4%跃升至2024年的71.7%[2]。与此同时，前沿模型性能趋于收敛，Chatbot Arena排行榜上排名第一与第十的模型间Elo分差从2023年的11.9%收窄至2025年初的5.4%，排名前两位的差距从4.9%缩小到0.7%[2]。竞争格局也在变化：2024年1月顶尖闭源模型相对开源模型的性能优势为8.0%，到2025年2月已缩小至1.7%；中美模型在MMLU、MMMU、MATH和HumanEval上的性能差距，从2023年底的17.5、13.5、24.3和31.6个百分点，收窄至2024年末的0.3、8.1、1.6和3.7个百分点[2]。但能力提升并不均衡：在“人类最后的考试”中，最先进系统得分率仅8.80%；在前沿数学基准中仅解决2%的问题；BigCodeBench编码基准成功率仅35.5%，远低于人类的97%[2]。复杂推理仍是难题，尽管思维链等机制提升了性能，系统仍无法可靠解决本可通过逻辑推理获得确定性答案的问题，尤其是问题规模超出训练范围时，这一缺陷严重影响系统可信度，使其难以胜任高风险场景[2]。此外，新型推理范式如测试时计算虽显著提升性能——o1在国际数学奥林匹克资格考试中获74.4%而GPT-4o仅9.3%——但代价是运算成本激增至GPT-4o的6倍、推理速度降低30倍[2]。

****应用与产业：企业应用加速，投资反弹，区域差异显著。****人工智能应用正以前所未有的速度渗透社会生活，数以百万计的人在专业工作和休闲活动中高频使用；随着高性能、低成本和开源模型的普及，其可及性和影响力将进一步扩大[2]。经过短暂放缓后，企业对人工智能的投资出现反弹，生成式人工智能初创企业融资案例数量增加近三倍，商业应用在多年低迷后于2024年迎来显著增长，人工智能已从边缘领域成为业务价值的核心驱动力[2]。2024年全球企业人工智能投资规模创历史新高，增长26%[2]。应用普及率快速上升，78%的企业在2024年应用了人工智能技术，较前一年的55%明显提升[2]。但多数企业仍处于应用初期：在客户服务运营中使用人工智能的企业中有49%报告实现降本，供应链管理为43%，软件工程为41%，且成本降幅大多不足10%；营销与销售部门应用人工智能的企业中71%报告收入提升，但收入增幅普遍低于5%[2]。区域上，北美仍保持企业应用率领先，但大中华区是同比增长最快的地区之一，企业采用率提升27%，欧洲增长23%[2]。在机器人部署方面，中国在工业机器人领域仍占主导，2023年安装27.63万台，是日本的6倍、美国的7.3倍，自2013年超过日本以来全球份额从20.8%升至51.1%，但2023年差距略有缩小，标志扩张势头略有放缓[2]。应用层面还出现了具体落地案例：2023年美国食品药品监督管理局批准的人工智能医疗设备达223款，较2015年的6款实现跨越式增长；自动驾驶方面，Waymo每周提供超过15万次自动驾驶乘车服务，百度Apollo Go自动驾驶出租车服务已覆盖中国众多城市[2]。在体育领域，有研究指出人工智能技术已渗透至体育各环节，从运动员训练到赛事运营，数据驱动的决策系统正在重塑体育行业的未来[4]。

****产业基础设施与创新生态：算力、数据与人才构成关键支撑与约束。****人工智能创新生态包括纵向的数据平台、开源算法、计算芯片、基础软件、图形处理器等技术生态系统，以及横向的智能制造、智能医疗、智能安防、智能零售、智能家居等商业和应用生态系统；目前智能科技时代的信息产业格局尚未形成垄断，全球科技产业巨头都在积极推动技术生态研发布局[1]。但基础设施约束正在显现。公共数据资源迅速萎缩，人工智能模型训练依赖海量公开网络数据，而2023至2024年间数据使用限制显著增加，在C4通用爬取数据集持续维护的域名中，受限制文本数据的比例已从5%—7%骤升至20%—33%，这种下降态势将影响数据多样性、模型对齐性和系统可扩展性，并可能催生数据约束条件下的新型学习范式[2]。能源也成为重要约束，人工智能正在推动能源结构变革并引发对核能的新一轮关注，微软宣布以16亿美元重启三哩岛核反应堆为人工智能提供动力，谷歌和亚马逊也签订了核能协议[2]。人才与教育方面，高校中人工智能使用已极为普遍，86%的学生在学习中使用人工智能，61%的教师在教学中使用；但至2025年初仅有39%的高等教育机构制定了人工智能相关“可接受使用政策”，尽管这一比例较2024年增长了16个百分点[2]。全球范围看，明确在国家课程中纳入人工智能教育的国家仍属少数，多数国家虽在战略层面强调其重要性但尚未提出具体实施方案；截至2023年，撒哈拉以南非洲地区仅有34%的小学具备电力供应，基础设施匮乏制约了相关课程实施[2]。

****治理状态：从讨论转向投资与监管，全球协作加强但评估与信任滞后。****各国政府正在加大参与力度，政策制定者不再停留于讨论人工智能，而是对其进行投资，一些国家启动了价值数十亿美元体量的国家人工智能基础设施计划，包括能源扩容等重大努力，全球协作机制日益完善[2]。2024年全球在人工智能治理领域的合作加强，重点转向协商确定负责任的人工智能原则：经济合作与发展组织更新了人工智能原则，强调包容性增长、透明度和可解释性；非洲联盟推出非洲大陆人工智能战略；欧盟通过了《人工智能法》，这是全球主要经济体首个全面的

人工智能监管框架，按风险对人工智能进行分类监管并确保高风险系统提供商承担主要义务；欧洲委员会通过了一项具有法律约束力的人工智能条约；联合国更新了治理报告，概述建立全球人工智能治理机制的努力；首个国际人工智能安全研究所网络成立，联合九個国家和欧盟开展全球人工智能安全合作[2]。然而，治理落地仍存明显落差。依据负责任的人工智能准则对系统进行评估的做法尚未普及，主要工业模型开发商采用标准化评测仍然很少见[2]。人工智能事件报告数量持续增加，2024年报告的相关事件增至233起，创历史新高，比2023年增加56.4% [2]。各类机构虽意识到风险，但缓解措施滞后：在领导者最关注的风险维度中，模型准确性问题（64%受访者提及）、合规性风险（63%）和网络安全威胁（60%）位列前三，但将这些风险列为核心关注点的受访者比例均未超过65%[2]。基础模型研究透明度虽有提高，主要模型开发者的平均透明度得分从2023年10月的37%提高到2024年5月的58%，但仍有较大改进空间[2]。公众信任方面，对人工智能公司保护个人数据的信心从2023年的50%下降到2024年的47%，相信人工智能系统不偏不倚、不受歧视的人也越来越少[2]。全球对人工智能的态度呈谨慎乐观：三分之二的人认为人工智能驱动的产品与服务将在未来3至5年内显著改变日常生活，较2022年上升6个百分点；但乐观程度存在明显地区差异，中国（83%）、印度尼西亚（80%）和泰国（77%）多数人认为人工智能利大于弊，而加拿大（40%）、美国（39%）和荷兰（36%）仅少数人持此观点[2]。

需说明的是，上述现状判断主要依据2019年与2025年两份公开资料，二者时间跨度较大，早期资料反映的产业格局与投资数据（如2016—2017年全球研发投入与创业公司数据）[1]与2024—2025年数据不宜拼接为连续序列，只能分别作为相应时点的口径参考。

三、趋势

1、本章摘要

综合现有证据，未来一段时期人工智能领域值得关注的变化方向集中在五个方面：模型能力继续向复杂推理与高难度基准推进，但基准趋于饱和、评测方法本身正在重构；单位智能成本与推理成本快速下降，先进模型的使用门槛持续降低；开源模型与闭源模型的性能差距基本消失，前沿模型性能趋于收敛，中美模型能力差距显著收窄；人工智能智能体（agent）自主性提升并进入落地环节，但从实验到正式运营的转化并不顺畅；生成式人工智能的企业使用率和公众预期同步上升，同时数据资源约束、信任下降与治理框架成型构成并行的限制条件。上述方向多由行业观察和宏观综述支持，缺少可核验的量化时间序列与反证条件，因此宜作为方向性判断而非确定性预测。

2、正文

模型能力将继续向复杂推理和高难度任务推进，但衡量能力的方式正在改变。2023年以来新提出的MMMU、GPQA和SWE-bench等基准，意在测试前沿系统的极限，而仅一年后成绩即大幅提升，其中SWE-bench编程解题能力从2023年的4.4%跃升至2024年的71.7%[2]。与此同时，MMLU、GSM8K、HumanEval等传统基准已趋近饱和，促使研究者转向更具挑战性的评测，例如最先进系统在“人类最后的考试”中得分率仅8.80%、在前沿数学基准中仅解决2%的问题[2]。这一组合证据指向两个短期变化：一是既有基准上的分数提升会继续，但其区分度下降；二是评测重心将转向更难任务与更贴近真实工作场景的评估。需要注意的是，复杂推理仍是人工智能面对的难题，思维链等机制虽显著提升了大语言模型性能，却未消除这一约束[2]；测试时计算等新推理范式虽大幅提升性能，但代价是运算成本和推理速度的显著恶化，例如o1的运算成本增至GPT-4o的6倍、推理速度降低30倍[2]。因此，能力提升与成本、时延之间的权衡，是判断该趋势可持续性的关键条件。

单位智能成本与推理成本的快速下降，是当前最具持续性的方向之一。有行业观察指出，单位智能成本在过去几年中每年约有40倍的降幅[5]；斯坦福人工智能指数报告的估算则显示，执行GPT-3.5级别任务的系统推理成本在2022年11月至2024年10月间下降超过280倍，硬件层面年化成本降幅约30%、能效年提升率约40%[2]。这些数字来自不同机构、口径并不统一，但方向一致：先进人工智能的应用门槛正在迅速降低[2]。其驱动因素包括小型模型能力跃升——2022年在MMLU上达到60%以上分数的最小模型是5400亿参数的PaLM，而2024年微软Phi-3-mini仅用38亿参数即达到同等水平[2]——以及硬件成本与能效的持续改善[2]。IBM的年度趋势回顾同样将“大幅降低推理成本”列为2025年上半年推动行业发展的主要变化之一[6]。该趋势的限制条件在于：成本下降主要发生在推理侧，训练侧成本与能耗并未同步下降；同时，推理成本估算的方法与样本口径在来源间并不一致，因此上述倍数关系宜视为量级判断而非精确数值。

智能体自主性增强并从实验走向落地，但转化过程并不顺畅。微软亚洲研究院将“AI驱动的代理将拥有更高的自主性来执行更多任务”列为2025年值得关注的趋势之一，并引述其高管判断，过去一年众多个人和组织已从人工智能实验转向更有实际意义的落地应用[7]。商业领袖和AI决策者对生成式人工智能的使用率在一年内从55%激增至75%[7]。IBM的观察则提供了相反方向的限定：机构确实在推进人工智能应用，尤其在智能体领域，但从实验阶段到正式运营的转型“鲜少一帆风顺”，进展速度并非简单线性[6]。综合来看，智能体落地的方向较为明确，但其节奏受制于组织流程、可靠性与集成成本，短期内更可能表现为局部职能的渗透而非全面替代。斯坦福报告的调查也显示，在单一业务职能内应用人工智能并取得财务效益的企业中，多数反馈的效益水平仍处于较低区间，成本降幅大多不足10%，收入增幅普遍低于5%[2]，这与“落地加速”的叙事形成对照，提示落地深度仍处早期。

使用率上升与公众预期走高将延续，但数据约束、信任下降与治理收紧构成并行限制。全球范围内，三分之二的受访者认为人工智能驱动的产品与服务将在未来3至5年内显著改变日常生活，这一比例较2022年上升6个百分点[2]；认为人工智能产品和服务利大于弊的比例从2022年的52%上升至2024年的55%，其中此前最持怀疑态度的英国、德国、美国、加拿大和法国分别提升8%、10%、4%、8%和10%[2]。与乐观情绪上升同时出现的是信任下降：人们对人工智能公司保护个人数据的信心从2023年的50%降至2024年的47%，相信人工智能系统不偏不倚、不受歧视的人也在减少[2]。在供给侧，公共数据资源正在迅速萎缩，2023至2024年间数据使用限制显著增加，在持续维护的C4通用爬取数据集中，受限制文本数据的比例已从5%—7%骤升至20%—33%，报告认为这可能影响数据多样性、模型对齐性和系统可扩展性，并催生数据约束条件下的新型学习范式[2]。在制度侧，2024年全球人工智能治理合作明显加强，经合组织、欧盟、联合国、非盟等相继发布规范性框架，欧盟通过《人工智能法》这一主要经济体首个全面监管框架[2]。这些因素共同意味着，使用扩张不会在无约束条件下线性推进，数据可得性、公众信任与合规成本将共同塑造实际渗透速度。

短期变化与长期判断需要区分。从证据强度看，成本下降、开源与闭源差距缩小、使用率与公众预期上升，属于已有观测数据支持的方向，其延续性相对可判断，但仍受口径与样本限制。模型能力向复杂推理推进，属于方向明确但受成本与评测方法制约的中期趋势。智能体落地、通用智能进展以及人工智能对宏观经济的长期影响，则更多依赖机构判断与主题性表述：一方面，有观点认为能够自主发现新知识或帮助人类更高效探索知识的系统可能在未来产生深远影响，并预计2026年取得初步成果、2028年及以后实现更具意义的突破[5]；另一方面，也有分析提示大语言模型应用推广中会面临难以解决的技术问题和实际困难，可能再次引发热度回落，跨学科协作被视为抵御这种“冷落”的关键策略[4]。此外，人工智能对宏观经济的长期影响仍存争议，早期生产效率提升虽已可量化，但对整体经济的作用尚无定论[2]。在缺少可核验量化口径与反证条件的情况下，对上述长期判断宜保持方向性表述，避免将其作为确定事实。

四、建议

1、本章摘要

基于前文对人工智能发展现状、趋势与约束的分析，本章面向管理者与实践者提出分层建议：在治理与合规层面，宜以风险分级分类为共同逻辑，优先建立与自身风险等级相称的管理体系与记录机制；在风险识别层面，宜参照全周期、多维度的风险评估方法，设定触发条件而非一次性评估；在企业落地层面，宜在成本下降与采用率上升的窗口期内推进应用，同时正视“认知与行动之间的差距”；在能力与人才层面，宜将人工智能素养建设作为长期投入。上述建议均可追溯至现有资料中的框架、制度逻辑或调查发现，但多数属于分析性建议而非经验证的最优实践，其适用性取决于组织所在法域、业务场景与风险等级，不宜视为确定收益的承诺。

2、正文

一、以风险分级分类作为治理与合规的共同起点。现有资料显示，人工智能的技术复杂性、高度不确定性、情境依赖性和快速演变性，使传统静态、线性规制难以满足现实需求，各国（地区）多转向基于风险分级分类的规制模式[8]。这一模式的优点在于：通过预先识别风险及其发生可能性设定优先级，避免“一刀切”式规制带来的资源浪费与创新抑制，并通过风险—收益权衡和技术中立性原则在发展与权利保护之间寻找平衡[8]。对管理者而言，这意味着合规工作的第一步不是全面铺开，而是明确自身系统所处的风险等级与适用规则。欧盟《人工智能法案》即按风险对系统分类并施加相应监管，高风险系统的提供商承担主要义务[2]。我国层面，从2017年《新一代人工智能发展规划》提出风险分级分类治理思路，到2019年《新一代人工智能治理原则》确立“敏捷治理”原则，再到2023年《全球人工智能治理倡议》提出建立风险等级测试评估体系，已基本完成从原则倡导到制度确认的转变[8]。需要注意的是，当前缺乏全国层面统一的人工智能基本法，现行治理体系呈现碎片化与分散化特征，各部门在分类基准、标准适用和实施方式上缺乏一致性[8]。因此，建议管理者在依据风险等级配置资源的同时，预留规则调整空间，避免将合规体系过度绑定于单一部门口径。

四、把安全与负责任人工智能的治理要素落到具体机制。综合安全管理的视角，人工智能安全需要关注合规和治理、法律和隐私、安全控制、风险管控、弹性韧性五个方面，分别对应政策程序与报告、生成式人工智能的具体监管与隐私要求、降低风险的安全控制、潜在威胁识别与缓解措施，以及保持可用性并满足业务SLA的韧性设计[10]。欧盟《人工智能法案》对高风险系统提出的要求可作为机制清单的参照：建立持续性风险管理体系并记录所采取措施、确保训练验证测试数据集的高质量与代表性并消除可能导致禁止性歧视的偏见、在系统部署前准备并定期更新技术文档、自动记录使用日志以提供可追溯性、向部署者提供清晰全面的说明、以及设置与风险和自主性水平相称的人工监督措施，使人工操作员在必要时能够干预系统决策[11]。这些要求的共同指向是“可记录、可追溯、可干预”，对尚未建立相应机制的实践者具有直

接的清单价值。同时应注意，上述条款适用于欧盟法域下的高风险系统，其义务主体和适用范围均有明确限定，不宜直接等同于其他法域的合规要求。

五、在成本下降与采用上升的窗口期内推进企业应用，但校准收益预期。证据显示，执行GPT-3.5级别能力的系统推理成本在2022年11月至2024年10月间下降280多倍，硬件年化成本降幅达30%，能效年提升率达40%，开源模型与闭源模型在某些基准上的性能差距从8%缩小到1.7%[2]。这些趋势正在迅速降低先进人工智能的应用门槛[2]。从应用侧看，大中华区企业人工智能采用率提升了27%，是同比增长率最高的地区之一[2]。但在收益端，报告显示在单一业务职能内应用人工智能并取得财务效益的企业中，多数反馈效益仍处于较低区间：客户服务运营中49%的受访者报告实现降本，供应链管理为43%，软件工程为41%，且成本降幅大多不足10%；营销与销售部门71%的受访者报告收入提升，但增幅普遍低于5%[2]。据此，建议管理者在推进应用时以具体职能为单元设定可验证的效益指标，并对短期回报保持审慎预期。

六、正视风险认知与实际行动之间的差距，把负责任人工智能嵌入既有流程。调查显示，尽管多数机构能识别关键负责任人工智能风险，但并非所有机构都采取了积极应对措施；在领导者最关注的风险维度中，模型准确性问题（64%受访者提及）、合规性风险（63%）以及网络安全威胁（60%）位列前三，但将这些风险列为核心关注点的受访者比例均未超过65%[2]。在组织理念层面，64%的受访者倾向于安全第一的方法，但58%的受访者正在探索最低限度监督的智能体，这种分歧表明行业在负责任人工智能方面缺乏统一的战略方向[2]。此外，2024年报告的人工智能相关事件增至233起，创历史新高，比2023年增加56.4%[2]。对实践者的建议是：将负责任人工智能的要求嵌入需求评审、数据治理、测试验收和上线监控等既有流程节点，而不是作为独立的合规项目运行；在智能体等自主性较高的应用上，尤其需要明确监督强度与责任归属。

七、将人工智能素养与人才建设作为长期投入，并关注数据与信任约束。报告指出，随着人工智能技术持续演进，教育体系转型已刻不容缓，唯有如此才能确保未来技术的构建者充分意识到人工智能可能带来的风险并具备减缓其负面影响的能力；建议高等教育机构持续推进人工智能教育通道构建并阶段性监测成效，同时制定政策扩大课程获取的公平性、提升教师专业能力[2]。在外部约束方面，公共数据资源正在迅速萎缩，在C4通用爬取数据集持续维护的域名中，受限制文本数据的比例已从5—7%骤升至20—33%，这一态势将影响数据多样性、模型对齐性和系统可扩展性[2]。同时，公众对人工智能企业保护个人数据的信心从2023年的50%下降到2024年的47%[2]。因此，建议管理者在人才与数据两项基础投入上保持连续性，并将数据来源合规性与公众信任维护纳入长期风险管理，而非仅在项目启动阶段考虑。

八、关于建议适用条件的说明。上述建议主要建立在治理框架、监管文本与调查数据之上，其性质是分析性建议而非经实证检验的最优实践。其一，多数框架（如前沿风险管理框架、NIST生成式人工智能框架）为自愿性、方法论性质的指引，其在国内组织中的实际效果缺少公开评估[9][2]。其二，欧盟《人工智能法案》条款具有明确法域与主体限定，不能直接平移为其他市场的合规义务[11]。其三，企业收益数据来自受访者自报，且多数效益幅度较低，不宜据此推导确定回报[2]。其四，我国统一人工智能立法尚未出台，制度环境仍处演进中，基于现行分级分类逻辑设计的合规安排需要保留调整余地[8]。因此，建议管理者将本章建议作为决策的起

点和检查清单，结合自身风险等级、业务场景与法域要求进行裁剪，并在实施中建立反馈与更新机制。

统一参考来源

[1] 人工智能的历史、现状和未来 - 求是网。 https://www.qstheory.cn/dukan/qs/2019-02/16/c_1124114625.htm

[2] 介绍2025年人工智能指数报告 - Stanford HAI。 https://hai.stanford.edu/assets/files/haiaiindexreport2025chineseversion_061325.pdf

[3] 我国人工智能政策文本量化研究 —— 政策现状与前沿趋势。 <https://www.kjjb.org/fileup/HTML/2021-38-15-015.htm>

[4] [PDF] 人工智能技术与体育应用的现状与发展。 <https://www.sxsportsworld.com/rc-pub/front/front-article/download/97769777/lowqualitypdf/%E4%BA%BA%E5%B7%A5%E6%99%BA%E8%83%BD%E6%8A%80%E6%9C%AF%E4%B8%8E%E4%BD%93%E8%82%B2%E5%BA%94%E7%94%A8%E7%9A%84%E7%8E%B0%E7%8A%B6%E4%B8%8E%E5%8F%91%E5%B1%95.pdf>

[5] 人工智能发展趋势及应对策略 | OpenAI。 <https://openai.com/zh-Hans-CN/index/ai-progress-and-recommendations>

[6] 人工智能主要趋势 | IBM。 <https://www.ibm.com/cn-zh/think/insights/artificial-intelligence-trends>

[7] 2025年六大AI趋势展望 - Microsoft Research。 <https://www.microsoft.com/en-us/research/articles/6-ai-trends-in-2025>

[8] 我国人工智能风险分级分类监管制度研究 —— 域外比较与本土构建。 <https://www.kjjb.org/article/2026/1001-7348/2026-43-1-011.htm>

[9] 前沿人工智能风险管理框架(v1.0)。 <https://concordia-ai.com/wp-content/uploads/2025/07/Frontier-AI-Risk-Management-Framework-v1.0-cn.pdf>

[10] 企业智能之旅（6）：安全与负责任的 AI | 亚马逊AWS官方博客。 <https://aws.amazon.com/cn/blogs/china/the-journey-for-enterprise-to-use-artificial-intelligence-part-six>

[11] 欧盟人工智能法案：指南。 <https://www.twobirds.com/-/media/new-website-content/pdfs/capabilities/artificial-intelligence/eu-ai-act-guide-chinese-version.pdf>